

השוואת יבול: ארבע גישות

יבול מדוד בפועל, predicted_Yield המבוסס על מודל, והמודל המומלץ שלנו, בשפה פשוטה

מטע קדמה, חלקה A. עודכן 17.07.2026. אוניברסיטת בן גוריון בנגב.

לכל עץ קיימים שלושה מספרי יבול, והדוח הזה משווה ביניהם ישירות. יבול בפועל הוא היבול האמיתי, השקול, אמת המידה היחידה שיש לנו. predicted_Yield המבוסס על מודל הוא מספר שהופק ממודל קודם, שנבנה בעיקר ממדדי חופה וגדילה, לא משקילה אמיתית. המודל שלנו הוא מודל קטן שבנינו ובדקנו, המנבא יבול לפי זן, עוצמת פריחה, (EBI) אקלים וגדילת חופה. כל ההשוואות שלהלן משתמשות באותם 167 עצים (2022 ו 2023 יחד), אלה שבהם קיימים שלושת המספרים.

הדוח הזה מחולק לשני חלקים. חלק א' בודק תחזיות מול היבול האמיתי, השקול, אמת המידה היחידה שקיימת. חלק ב' מסתכל על predicted_Yield בפני עצמו, כאובייקט מחקר בזכות עצמו, על פני מדגם גדול יותר. שני החלקים מוצגים במלואם; השאלה הפתוחה בסוף חלק ב' מופנית ישירות למעבדה.

חלק א'

יבול אמיתי, נמדד. אמת המידה היחידה הקיימת במדגם הזה (n=167 עץ-שנה).

46% מול 29%

שונות ביבול האמיתי המוסברת: המודל שלנו מול predicted_Yield

חלק ב'

predicted_Yield המבוסס על מודל, בפני עצמו, על פני מדגם גדול יותר (n=1793 עץ-שנה).

84.4%


מהשונות של predicted_Yield עצמו מוסברת, חישה מרחוק בלבד

חלק א': יכול אמיתי, נמדד

נבדק מול היבול האמיתי, השקול, אמת המידה היחידה במדגם הזה ($n=167$) עץ-שנה, 2022 ו 2023 יחד).


התמונה הכללית

The big picture: which prediction is closer to the real, weighed yield?



מימין: מתוך כל ההבדלים בין העצים ביבול האמיתי, המודל שלנו מסביר נכון כ, 46% ו `predicted_Yield` מסביר כ. 29% משמאל: בטעות, טעות המודל שלנו היא 0.97 ק"ג לעץ, וטעות `predicted_Yield` היא 1.19 ק"ג לעץ (היבול האמיתי הממוצע הוא כ 3.16 ק"ג). המודל שלנו קרוב יותר בשני המדדים.

כל עץ, זה לצד זה




מסודרים מהיבול האמיתי הנמוך ביותר לגבוה ביותר (הקו הירוק). הנקודות הכתומות (`predicted_Yield`) העצים

נשארות שטוחות למדי ולא עולות הרבה גם כשהיבול האמיתי מטפס, בעיקר בצד ימין של הגרף, העצים בעלי היבול הגבוה ביותר. הנקודות הכחולות (המודל שלנו) עולות ויורדות בהתאמה קרובה יותר לקו הירוק, במיוחד בקצה היבול הגבוה.

1-2. predicted_Yield המבוסס על מודל מול יבול בפועל, והמודל שלנו מול יבול בפועל

Side by side: same real trees, same scale, two different predictions




אותם עצים אמיתיים, אותו קנה מידה בציר, ממוקמים זה לצד זה בכוונה. משמאל: `predicted_Yield` מול יבול בפועל, $r=0.54$ מסביר 29% מהשונות ביבול האמיתי. מימין: המודל שלנו מול יבול בפועל, $r=0.73$ על הנתונים שעליהם הותאם (53% מוסבר, $n=167$ בשני הלוחות, נקודות הקרובות יותר לקו המקווקו 1:1 מדויקות יותר; קו המגמה הכתום בלוח השמאלי יושב באופן ניכר מתחת לאלכסון, וקו המגמה הכחול בלוח הימני עוקב אחריו בצורה קרובה יותר.

`predicted_Yield` מסוגל לשחזר את עצמו כמעט בשלמות (94 עד 96% כשהוא נבדק מול המרכיבים שלו עצמו, אבל כאן, מול סקאלה אמיתית, הוא מסתדר הרבה פחות טוב. הפער הזה הוא הממצא המרכזי: להיראות מדויק על הנייר לא אומר שהוא מנבא היטב את היבול האמיתי.

הערה על המספר של המודל שלנו: 53% (המוצג למעלה) הוא עד כמה הוא מתאים לאותם הנתונים שעליהם הוא נבנה, מה שתמיד קצת אופטימי מדי. המבחן ההוגן והמחמיר יותר (התאמה על חלק מהעצים, ובדיקה על עצים אחרים שהמודל מעולם לא ראה) נותן, וזה המספר שיש לסמוך עליו לגבי איך המודל יתנהג על עץ חדש. גם ב, 46% המודל עדיין ברור לפני `predicted_Yield` שנמצא ב. 29%.

4. המודל שלנו מול predicted_Yield המבוסס על מודל



($n=167$, $r=0.75$), כאן, אף אחד מהמספרים אינו היבול האמיתי, זה רק בודק האם שני המודלים מסכימים זה עם זה. הם מסכימים, במידה רבה, אבל זה צפוי ולא מרגיע: שניהם משתמשים בזן ובמדדי גדילה חופפים כקלט, כך שחלק מההסכמה פשוט נובע משיתוף מרכיבים. שני מודלים שמסכימים זה עם זה לא כמו שאחד מהם צודק לגבי היבול האמיתי, רק ההשוואות מול היבול בפועל (סעיפים 1 ו 2) קובעות זאת.

שורה תחתונה (מאוחד, שני הזנים יחד)

כשבודקים מול היבול האמיתי, השקול, המודל שלנו קרוב באופן ברור יותר מ: predicted_Yield הוא מסביר יותר מהשונות האמיתית (46%) מול (29% והטעות הממוצעת שלו לעץ קטנה יותר 0.97) ק"ג מול 1.19 ק"ג). predicted_Yield נראה מדויק הרבה יותר על הנייר רק כי הוא מתבקש לשחזר מספר שנבנה מהמרכיבים שלו עצמו. המודל שלנו, אף שהוא צנוע לפי סטנדרטים של הצלבה, (CV) הוא זה שנבדק בפועל מול מה שבאמת ירד מהעצים, וקרוב יותר אליו.

השוואה סטטיסטית מלאה

השוואה	r	R ²	MAE (ק"ג)	p-value	n
predicted_Yield מול יכול בפועל	0.54	29%	1.19	<0.001	167
המודל שלנו מול יכול בפועל (התאמה על נתוני האימון שלו)	0.73	53%	0.97	<0.001	167
המודל שלנו מול יכול בפועל (מאומת בהצלבה, המספר ההוגן)	-	46%	1.02	-	167
המודל שלנו מול predicted_Yield (הסכמה בלבד, לא דיוק)	0.75	56%	-	<0.001	167


למה שני מספרי R² למודל שלנו: 53% הוא עד כמה הוא מתאים לאותם הנתונים שעליהם נבנה, תמיד קצת אופטימי מדי. 46% הוא המבחן המחמיר יותר, התאמה על חלק מהעצים ובדיקה על אחרים שמעולם לא נראו, וזה המספר שמנבא איך המודל יתנהג על עץ חדש. MAE מאומת בהצלבה (1.02 ק"ג) גבוה במעט בדומה מ MAE בתוך המדגם (0.97 ק"ג) מאותה סיבה; שניהם עדיין הרבה לפני 1.19 ק"ג של predicted_Yield.

כעת מפוצל לפי זן

הממצא המרכזי של המטע הזה הוא שהזן משנה את הקשר בין פריחה ליבול, ולכן כל השוואה למעלה חוזרת בנפרד עבור UEF (n=96) עץ-שנה וזן (n=71) 53 עץ-שנה.

התמונה הכללית, לפי זן

The big picture, split by cultivar




המודל שלנו מסביר 47% מהיבול האמיתי מול 28% של predicted_Yield, טעות ממוצעת 0.99 ק"ג מול UEF:

1.01 ק"ג. זן 53: המודל שלנו מסביר 60% מול 44% של predicted_Yield, טעות ממוצעת 0.94 ק"ג מול 1.43 ק"ג. המודל שלנו קרוב יותר ליבול בפועל בשני הזנים, והפער גדול ביותר בזן 53.

predicted_Yield מול יכול בפועל, והמודל שלנו מול יכול בפועל, 1-2. לפי זן


Predicted vs. actual, split by cultivar (each row is one cultivar)



שורה עליונה: עצי UEF שורה תחתונה: עצי זן 53. אותו קנה מידה בציר בתוך כל שורה כך ששתי העמודות ניתנות להשוואה ישירה. בשני הזנים העמודה הימנית (המודל שלנו) יושבת קרוב יותר לקו המקווקו 1:1 מאשר העמודה השמאלית. (predicted_Yield).

3. כל עץ, לפי זן


Every tree, side by side, split by cultivar



אותה פריסה כמו הגרסה המאוחדת, לוח אחד לכל זן, עצים מסודרים לפי יבול בפועל בתוך הזן שלהם. הנקודות הכחולות (המודל שלנו) עוקבות אחרי הקו הירוק (בפועל) בצורה קרובה יותר מהנקודות הכתומות (predicted_Yield) בשני הלוחות.

4. המודל שלנו מול predicted_Yield המבוסס על מודל, לפי זן

Our model vs. modelled predicted_Yield, split by cultivar



UEF: $r=0.75$ (56%, $n=96$), 53: $r=0.90$ (81%, $n=71$) גבוה באופן ניכר מ. UEF כמו בגרסה המאוחדת, זו הסכמה בין שני פלטי מודל, לא אימות מול יבול אמיתי, כך שמספר גבוה יותר כאן הוא לא בהכרח בשורה טובה. בזן 53 באופן ספציפי, יש להתייחס להסכמה החזקה הזו בזירות נוספת: $n=71$ הוא מדגם צנוע לפיצול נוסף, ושני המודלים חולקים זן Growth_April כקלט, כך שחלק מההתאמה הגבוהה במיוחד יכול לשקף מרכיבים משותפים ומדגם קטן יותר ולא שאחד המודלים נכון יותר לגבי היבול האמיתי של זן 53.

שורה תחתונה, לפי זן

בשני הזנים, המודל שלנו עוקב אחרי היבול האמיתי, המדוד, בצורה קרובה יותר מ predicted_Yield בכל מדד שנבדק: יותר שונות מוסברת, טעות ממוצעת קטנה יותר, והתאמה חזותית הדוקה יותר לקו 1:1. הפער בין המודל שלנו ל predicted_Yield רחב יותר בזן 53 מאשר ב UEF. זהו ממצא כיווני ב $n=71$ ו $n=96$ לא המבחן העצמאי לגמרי, המאומת בהצלבה לפי זן, שהפרויקט הזה היה מריץ לפני קביעת טענה ספציפית לזן; R^2 המאומת בהצלבה של המודל המאוחד, 0.456, נשאר המספר המרכזי וההוגן של הפרויקט.

MAE שלנו (ק"ג)	MAE חזוי (ק"ג)	R^2 שלנו	R^2 חזוי	יבול ממוצע (ק"ג)	n	זן
0.99	1.01	47%	28%	3.38	96	UEF
0.94	1.43	60%	44%	2.85	71	זן 53

שיפור ה MAE של זן 53 (1.43 ל 0.94 ק"ג, קיצוץ של 34%) הוא הרווח הגדול ביותר מכל קבוצה במטע; רווח השונות המוסברת של UEF גדול 28% ל 47% אבל ה MAE שלו נשאר כמעט שטוח, מכיוון ש predicted_Yield של UEF כבר היה קרוב יחסית בטעות הממוצעת גם כשהוא הסביר פחות מהפיזור האמיתי.

הפריחה שעליהם מבוסס המודל הזה נלקחים בפברואר, חמישה חודשים לפני הקציר. תחזית שנבנית מהם צילומי

זמינה לתכנון כוח אדם, אחסון ולוגיסטיקה מוקדם הרבה יותר מהקציר עצמו, ואינה דורשת המתנה לרכישה של יולי כפי שחלק מהממדים הספקטריים שנבדקו במקומות אחרים בפרויקט דורשים.

מכיוון שהקשר בין פריחה ליבול פועל בכיוונים הפוכים לפי זן, יותר עוצמת פריחה מנבאת יותר יבול ב UEF ($r=+0.29$) אבל פחות יבול בזן, ($r=-0.26$) 53 ממוצע אחיד לכל המטע היה מפספס את זה לגמרי. פיצול המודל לפי זן הוא מה שמאפשר לו לסמן גוש עם ביצועים נמוכים לפני שהפער ביבול מתגלה בקציר, ולא אחריו. אותה גישה של רחפן ומודל ישימה לכל גוש עם זהות זן וצילומי פריחה, היא אינה ייחודית לחלקה A.

שום דבר מכל זה לא משנה את התקרה ההוגנת של המספרים למעלה: 46% מהשונות ביבול האמיתי מוסברים, מאומת בהצלבה, הוא תוצאה אמיתית ולא קטנה מול בסיס של 29%, אבל זה לא מוצר תחזית מוגמר. המנוף היחיד הגדול ביותר לשיפור נוסף הוא עוד עונות של יבול מדוד, לא תכונות חדשות או מודלים חלופיים; ארבע עשרה משפחות מודל אחרות נבדקו מול המודל הזה במהלך הפרויקט ואף אחת לא עברה אותו.

הערה על העצים הבולטים: העצים בעלי היבול הגבוה והנמוך ביותר במדגם נבדקו כחריגים אפשריים, ובנפרד, ארבע עשרה מודלים (מוסדרים, עמידים ולא-לינאריים) נבדקו מול המודל הזה. שתי הבדיקות הסכימו שהעצים הקיצוניים נושאים מידע אמיתי ומוסבר חלופיים

נכון ולא רעש, ואף אחד מהמודלים החלופיים לא עבר את זה, כך שכולם נשארים בכל מספר למעלה במקום להיות מוסרים.

חלק ב': predicted_Yield המבוסס על מודל

predicted_Yield נבדק בפני עצמו: אילו תכונות מסבירות אותו הכי טוב, ועד כמה, על פני מדגם גדול הרבה יותר (1793 עץ-שנה, 2022 ו 2023 לעומת 167 בחלק א').

מה מסביר הכי טוב את predicted_Yield

שאלה נפרדת מחלק א': לא עד כמה מודל מנבא את היבול האמיתי, אלא אילו תכונות מסבירות הכי טוב את מספר predicted_Yield הקיים עצמו. זה לא דורש את קובץ היבול המדוד, כך שזה רץ על מדגם גדול הרבה יותר, כל עץ UEF וזן 53 עם ערך predicted_Yield ב 2022 או 1793) 2023 עץ-שנה, לעומת 167 בחלק א').

תכונות פיזיולוגיה הידועות כמרכיבים כמעט-ישירים של הבנייה של predicted_Yield עצמו (SWP) וגדילה באפריל/מאי-יוני/יולי, CNC_June ושדות האשכול; CNC_June לבדו מתואם ב $r=+0.95$ עם predicted_Yield) הוצאו בכוונה מהחיפוש. הכללתם לא הייתה חיפוש תכונות אמיתי, זה היה פשוט משחזר את התווית מהמרכיבים הידועים שלה עצמה. מאגר המועמדים כאן הוא חישה מרחוק בלבד: זן, עוצמת פריחה (EBI) והאינטראקציה שלה עם הזן, אקלים, גדילת חופה, בתוספת אותו מאגר של 34 עמודות מהונדסות (מבנה חופה, פיזור פיקסלים של EBI מדדים מורכבים) המשמש בכל הפרויקט.

MAE (ק"ג)	AIC	R ² (CV)	תכונות	מודל
0.37	2810	84.4%	זן, EBI x cultivar, אקלים, Growth_April	בסיס (4 תכונות)
0.37	2810	84.4%	אותן 4, אף אחת מ 34 לא נוספה	מודל חישה-מרחוק-בלבד הטוב ביותר (חיפוש על 34 מועמדים)
0.26	1249	93.5%	+ CNC_June, Growth_June	עם SWP/Growth_May_June/Growth_June/CNC_June מוחזרים

תוצאה: ארבע תכונות הבסיס לבדן כבר מסבירות 84% מהשונות של predicted_Yield, מאומת בהצלחה, גבוה בהרבה מתקרת 46% של היבול האמיתי, המדוד, למעלה. סינון שיטתי של הוספת-אחד על כל 34 המועמדים המהונדסים, ואחריו בחירה קדימה, לא מצא שום דבר ששווה להוסיף: המועמדים הקרובים ביותר היו EBI_x_CanopyCover ($\Delta AIC=-7.4$, ΔCV ; $R^2=+0.07$ CanopyCover נק'); ($\Delta AIC=-11.2$, ΔCV BrightFraction_x_CanopyArea נק'); ($\Delta AIC=-0.3$, ΔCV $R^2=+0.04$ נק'); ($\Delta AIC=-0.02$, ΔCV $R^2=-0.02$ נק'), כולם זניחים במונחים מעשיים למרות המדגם הגדול. החיפוש הוסיף אפס תכונות; הבסיס של 84% עומד כמודל חישה-מרחוק-בלבד הטוב ביותר שנמצא.

השורה התחתונה בטבלה למעלה מראה מה קורה כשמחזירים את שדות הפיזיולוגיה שהוצאו, בדיוק הבדיקה שהתבקשה. הוספת CNC_June לבדו מקפיצה את R^2 המאומת בהצלחה מ 84.4% ל 93.2% בצעד אחד (88.4%, $\Delta AIC=-1478$, שיפור עצום, לא שולי), ו Growth_June לבדו היה עושה כמעט אותו הדבר בעצמו, $\Delta AIC=-537$ בחירה קדימה עם כל השדות זמינים בוחרת בדיוק בשני אלה ועוצרת ב $R^2=93.5\%$ מאומת בהצלחה, כש AIC יורד מ 2810 ל 1249 ו MAE מ 0.37 ק"ג ל 0.26 ק"ג, קפיצות גדולות בהרבה מכל אחד מ

34 המועמדים הלגיטימיים של חישה מרחוק, בנפרד או יחד.

זו המחשה קונקרטית של דאגת המעגליות שצוינה למעלה: CNC_June ו Growth_June קרובים לחשבון האריתמטי שמודל האשכול השתמש בו כדי להפיק את predicted_Yield מלכתחילה, וזו סיבה סבירה לכך ששדה אחד לבדו עולה על כל 34 מועמדי חישה מרחוק יחד. הנתון של 84.4% חישה-מרחוק-בלבד עונה על השאלה המרכזית של החלק הזה; הנתון של 93.5% עם שדות הפיזיולוגיה כלולים עונה על שאלה שונה וצרה יותר, עד כמה ניתן לשחזר את predicted_Yield משדות קרובים לבנייה שלו עצמו, ומוצג כאן לשלמות ולא כתוצאה המרכזית.

האם Random Forest עושה טוב יותר

מול OLS	R ² (CV)	תכונות	מודל
בסיס	84.4%	4 תכונות בסיס	OLS, חישה מרחוק בלבד
+1.0 נק'	85.4%	אותן 4 תכונות בסיס	Random Forest, חישה מרחוק בלבד
+1.0 נק'	85.4%	38 תכונות, בחירה עצמית של RF	Random Forest, + 34 מועמדים מהונדסים
(ראו הערה)	93.5%	+ CNC_June, Growth_June	OLS, עם שדות פיזיולוגיה
(ראו הערה)	98.7%	44 תכונות, בחירה עצמית של RF	Random Forest, עם שדות פיזיולוגיה

Random Forest (אותה הטמעה built from scratch ואותו פרוטוקול כוונון המשמשים בכל הפרויקט, כוונון מחדש עבור המדגם הגדול הרבה יותר הזה) נבדק מול שתי הגרסאות של החיפוש הזה. בהשוואת RF עולה על OLS בצמצום: 85.4% מול R^2 84.4% מאומת בהצלבה, רווח אמיתי אך צנוע חישה-מרחוק-בלבד, כנקודה אחת. מתן גישה ל RF ל 34 המועמדים המהונדסים האחרים לא מוסיף שום דבר נוסף, (85.4%) זהה של לתוצאת ארבע התכונות), מה שמסכים עם ממצא הבחירה-קדימה של OLS למעלה בשיטה שונה: אין סטטיסטית יותר בתוך 34 התכונות האלה לא עבור מודל לינארי ולא עבור מודל לא-לינארי למצוא.

כשמחזירים את שדות הפיזיולוגיה, R^2 מאומת בהצלבה מגיע ל 98.7% הרבה מעל ה 93.5% של CNC_June. OLS לבדו מתואם ב $r=+0.95$ עם predicted_Yield ומודל לא-לינארי גמיש עם רוב 44 התכונות שלו זמינות בכל פיצול נמצא במצב טוב להתאים לקשר הזה מקרוב. יש לקרוא זאת כ Random Forest ששחזר את predicted_Yield משדות קרובים לבנייה שלו עצמו, ולא כמודל חזק יותר של התופעה שמתחת. כמו בהשוואת OLS המספרים של חישה-מרחוק-בלבד הם המרכזיים לחלק הזה; המספרים עם שדות הפיזיולוגיה, OLS או RF מוצגים לשלמות.

מה 34 התכונות המהונדסות (וגם 4 תכונות הבסיס) באמת תורמות (חשיבות permutation של RF)

גרסה קודמת של הטבלה הזו השתמשה בחשיבות מבוססת-פיצול (Gini) של RF, המדד הסטנדרטי, אבל יש לו הטיה ידועה: הוא מתגמל תכונות שמפוצלות לעיתים קרובות, מה שמעדיף תכונות רציפות על פני בדידות בלי קשר לגודל האפקט האמיתי. ההטיה הזו התגלתה כאן באופן קונקרטי: אקלים (Chill Portions) הוא ברמת תחנה, בדיוק 2 ערכים במדגם הזה (35 ב 2022, 25 ב 2023) אותה בדידות כמו מדד הזן הבינארי, ובכל זאת חשיבות מבוססת-פיצול דירגה אותו הרבה מעל הזן. הסתבר שהסיבה אמיתית, לא תוצר של בדידות: הפיצול היחיד הזמין של אקלים מפריד את predicted_Yield ב 2.43 ק"ג בין השנים, לעומת רק 0.21 ק"ג בין הזנים, כך שהפיצול היחיד של אקלים פשוט הרבה יותר אינפורמטיבי, לא תדיר יותר.


הטבלה הזו במקום זאת משתמשת ב: permutation importance אחרי אימון היער של כל fold, מערבבים תכונה אחת בכל פעם בתוך fold הבדיקה בלבד ומודדים את הירידה ב R^2 מאומת בהצלבה, באמצעות אותם עצים (בלי אימון מחדש). ממוצע על 5 זרעים על 5 folds על 25 עצים לכל R^2 fold בסיס מאומת עקבי עם הנתון של 85.4% למעלה). בניגוד לחשיבות מבוססת-פיצול, זה לא מוטה לפי כמה בהצלבה=4.58%, ערכים נבדלים יש לתכונה, רק לפי כמה הדיוק של המודל באמת תלוי בה.

תוצאה: הזן נראה שונה לגמרי לפי המדד ההוגן יותר הזה. ערבוב זן עולה 0.81 נקודות, R^2 הירידה הרביעית בגודלה מכל 38 התכונות, הרבה מעל הרשומה הטובה ביותר של המאגר המהונדס (EBI_Norm_skew, 1.14 נקודות). ערבוב אקלים עולה 101 נקודות, למעשה מחסל את המודל, מה שמאשר אותו כגורם הדומיננטי היחיד של predicted_Yield במדגם הזה. EBI הבסיסי (עוצמת פריחה ממוצעת) עדיין תורם כמעט שום דבר בפני עצמו (+0.001 נקודות, דירוג 28 מתוך 38), עקבי עם הממצא המבוסס של הפרויקט שרמת הפריחה הממוצעת שטוחה וזה השונות/הזנבות וזהות הזן שנושאים את האות האמיתי ליבול בפועל.

הסבר	ירידת R ²	תכונה	#
Chill Portions (Dynamic Model), ברמת תחנה: 35 ב 2022, 25 ב 2023.	+100.64₈	climate	1
נדילת חופה שנמדדה באפריל.	+9.285	Growth_April	2
אי סימטריה של התפלגות EBI בחופה.	+1.145	EBI_Norm_skew	3
מדד זן (1 = UEF, 0 = 53)	+0.813	cultivar(UEF)	4
EBI כפול אחוז כיסוי החופה.	+0.175	EBI_x_CanopyCover	5
יחס פיקסלי חופה מתוך (חופה + קרקע).	+0.148	CanopyCover	6
אחוזון 10 של EBI לפיקסל.	+0.130	EBI_Norm_P10	7
מקדם השונות של EBI בחופה (פזרנות).	+0.075	EBI_Norm_CV	8
BrightFraction כפול שטח חופה.	+0.071	BrightFraction_x_Canopy Area	9
EBI ליחידת שטח חופה.	+0.051	EBI_density	10
אחוז משטח הבסיס המסווג כצל (סף). (Otsu)	+0.051	ShadowFraction	11
עוצמת פריחה מתוקנת תאורה: EBI כפול 1 פחות. (Shadow)	+0.039	ICBI	12
חדות התפלגות EBI בחופה.	+0.039	EBI_Norm_kurtosis	13
EBI כפול שטח חופה (עוצמה כפול גודל).	+0.029	BloomVolume	14
BloomFraction כפול ספירת פיקסלי חופה.	+0.023	BloomPixelVolume	15
פיקסלים בהירים בחופה בכלל, לא ספציפי לפריחה.	+0.022	BrightFraction	16
שטח חופת העץ במ"ר.	+0.022	CanopyArea	17
שונות של EBI בתוך החופה.	+0.022	EBI_Norm_var	18
EBI כפול BloomFraction.	+0.019	EBI_x_BloomFraction	19
פיקסלי חופה שסווגו כפריחה (סף Otsu על בהירות).	+0.015	BloomFraction	20
עוצמת פריחה אחידה: EBI כפול 1 פחות. (EBI_Norm_CV)	+0.010	UBI	21
פיקסלים עם EBI מעל 0.65 למ"ר.	+0.010	HighEBI_density_065	22
עומס פריחה כולל מתוקן תאורה: שטח כפול EBI כפול 1 פחות. (Shadow)	+0.009	TICBL	23
אחוזון 25 של EBI לפיקסל.	+0.008	EBI_Norm_P25	24
אחוז פיקסלים עם EBI מעל 0.75.	+0.007	HighEBI_frac_075	25
אחוז מעל סף Otsu ספציפי ל EBI.	+0.005	EBI_OtsuFrac	26
פריחה מותאמת שלמות חופה: HighEBI_frac_065 כפול CanopyCover.	+0.005	CCAB	27
EBI ממוצע של החופה (עוצמת פריחה כללית).	+0.001	EBI	28
אחוזון 90 של EBI לפיקסל.	-0.001	EBI_Norm_P90	29
עומס פריחה כולל: שטח חופה כפול HighEBI_frac_065.	-0.002	TBL	30
חציון EBI לפיקסל בחופה.	-0.003	EBI_Norm_median	31
סטיית תקן של EBI בתוך החופה.	-0.004	EBI_Norm_std	32
אחוזון 75 של EBI לפיקסל.	-0.005	EBI_Norm_P75	33
אחוז פיקסלים עם EBI מעל 0.55.	-0.008	HighEBI_frac_055	34
פיקסלים עם EBI מעל 0.75 למ"ר.	-0.008	HighEBI_density_075	35
אחוז פיקסלים עם EBI מעל 0.65 (סף הפרויקט).	-0.009	HighEBI_frac_065	36
טווח בין רבעוני (75 פחות 25) של EBI.	-0.012	EBI_Norm_IQR	37
פיקסלים עם EBI מעל 0.55 למ"ר.	-0.013	HighEBI_density_055	38


כל 38 התכונות (4 בסיס, מסומנות בענבר, בתוספת כל 34 המועמדים המהונדסים), מדורגות לפי ירידת R² ב, permutation מהגבוה לנמוך. ערכים שליליים אומרים שערבוב התכונה הזו שיפר מעט את הדיוק המאומת בהצלבה, סימן לרעש טהור, לא לאפקט שלילי אמיתי.

חשיבות: permutation ירידת R² לפי תכונה, כל 38



אותן 38 תכונות וערכים כמו בטבלה, כעמודות. משמאל: 4 התכונות עם אפקט אמיתי (לא רעש), סקאלה לינארית. מימין: 34 התכונות המהונדסות הנותרות, בזום לטווח הקטן הרבה יותר שלהן כך שההבדלים הקטנים ביניהן עדיין נראים.

נתח מסך התרומה החיובית, לפי תכונה



אחוז מסך כל ירידות ה R^2 החיוביות (28) מתוך 38 תכונות; 10 עם ירידה שלילית/רעש הוצאו)

תכונה מהונדסת (24) תכונות בסיס (4)

אותה תוצאה כנתח מהסך: מתוך 28 התכונות עם תרומה חיובית אמיתית כלשהי (10) האחרות עם ירידה שלילית, רעש בלבד, הוצאו כאן), אקלים לבדו מהווה, EBI_Norm_skew 1.0%, Growth_April 8.2%, climate 89.2% וזן 0.7% כל אחת מ 34 התכונות המהונדסות מהווה בנפרד הרבה פחות מ 0.2%.

למה זה חשוב לקריאת `predicted_Yield`: זה לא שחישה מרחוק במקרה מסבירה את היבול האמיתי בצורה גרועה (46%) אבל מסבירה את המספר האחר הזה היטב (84%) כי היא אות נסתר טוב יותר. זה ש `predicted_Yield` עצמו הוא מספר חלק, מיוצר-מודל, קרוב מבחינה מכנית לפונקציה של כמה קלטים מתואמים של גדילה, אקלים וזן, כך שקומץ תכונות רווה אותו כמעט מיד. יבול אמיתי, שקול, רועש יותר ולא רווה באותו אופן. עקביות פנימית גבוהה של `predicted_Yield` ודיוק צנוע, מאומת בהצלבה, מול היבול האמיתי הם שני צדדים של אותו ממצא שכבר נקבע בחלק א', לא סתירה.

שאלה פתוחה למעבדה: כל מה שבחלק הזה נובע מאופן הבנייה של `predicted_Yield`, לא מהנחה שהוא לא אמין. אם יש אימות של `predicted_Yield` מול מדגם גדול ובלתי תלוי של עצים עם יבול נמדד אמיתי (גודל מדגם, מתאם, שיטה), שיתוף שלו יתייחס ישירות לדאגת המעגליות שהועלתה למעלה. בהתאם למה שהאימות הזה יראה, `predicted_Yield` יכול לעבור באופן סביר ממודל שיש לפרש בזהירות לתחליף שמיש ליבול אמיתי, מה שישנה על איזה משני החלקים של הדוח הזה כדאי לפרויקט להמשיך ולבנות. נשמח לקבל את הנתונים האלה ונעדכן את הניתוח בהתאם.